# Hadoop 运行环境搭建

## 第1章 Hadoop 运行环境搭建

### 1.1 模板虚拟机环境准备

0) 安装模板虚拟机, IP 地址 192.168.10.100、主机名称 hadoop100、内存 4G、硬盘 50G



#### 1) hadoop100 虚拟机配置要求如下(本文 Linux 系统全部以 CentOS-7.5-x86-1804 为例)

(1) 使用 yum 安装需要虚拟机可以正常上网, yum 安装前可以先测试下虚拟机联网情况

```
[root@hadoop100 ~] # ping www.baidu.com
PING www.baidu.com (14.215.177.39) 56(84) bytes of data.
64 bytes from 14.215.177.39 (14.215.177.39): icmp_seq=1 ttl=128 time=8.60 ms
64 bytes from 14.215.177.39 (14.215.177.39): icmp_seq=2 ttl=128 time=7.72 ms
```

(2) 安装 epel-release

注: Extra Packages for Enterprise Linux 是为"红帽系"的操作系统提供额外的软件包,适用于 RHEL、CentOS 和 Scientific Linux。相当于是一个软件仓库,大多数 rpm 包在官方 repository 中是找不到的)。

[root@hadoop100 ~]# yum install -y epel-release

(3)注意: 如果 Linux 安装的是最小系统版,还需要安装如下工具,如果安装的是 Linux

#### 桌面标准版,不需要执行如下操作

▶ net-tool: 工具包集合,包含 ifconfig 等命令

[root@hadoop100 ~]# yum install -y net-tools

▶ vim: 编辑器

[root@hadoop100 ~]# yum install -y vim

#### 2) 关闭防火墙,关闭防火墙开机自启

```
[root@hadoop100 ~]# systemctl stop firewalld
[root@hadoop100 ~]# systemctl disable firewalld.service
```

注意: 在企业开发时,通常单个服务器的防火墙时关闭的。公司整体对外会设置非常安

#### 全的防火墙。

3) 创建 iflytek 用户,并修改 iflytek 用户的密码

[root@hadoop100 ~]# useradd iflytek

[root@hadoop100 ~]# passwd iflytek

#### 4) 配置 iflytek 用户具有 root 权限, 方便后期加 sudo 执行 root 权限的命令

[root@hadoop100 ~]# vim /etc/sudoers

修改/etc/sudoers 文件, 在%wheel 这行下面添加一行, 如下所示:

```
## Allow root to run any commands anywhere
root ALL=(ALL) ALL

## Allows people in group wheel to run all commands
%wheel ALL=(ALL) ALL
iflytek ALL=(ALL) NOPASSWD:ALL
```

注意:iflytek 这一行不要直接放到 root 行下面,因为所有用户都属于 wheel 组,你先

配置了 iflytek 具有免密功能,但是程序执行到%wheel 行时,该功能又被覆盖回需要密

码。所以 iflytek 要放到%wheel 这行下面。

#### 5) 在/opt 目录下创建文件夹,并修改所属主和所属组

(1) 在/opt 目录下创建 module、software 文件夹

```
[root@hadoop100 ~]# mkdir /opt/module
[root@hadoop100 ~]# mkdir /opt/software
```

(2) 修改 module、software 文件夹的所有者和所属组均为 iflytek 用户

```
[root@hadoop100 ~]# chown iflytek:iflytek /opt/module
[root@hadoop100 ~]# chown iflytek:iflytek /opt/software
```

(3) 查看 module、software 文件夹的所有者和所属组

```
[root@hadoop100 ~] # cd /opt/
[root@hadoop100 opt] # ll
总用量 12
drwxr-xr-x. 2 iflytek iflytek 4096 5月 28 17:18 module
drwxr-xr-x. 2 root root 4096 9月 7 2017 rh
drwxr-xr-x. 2 iflytek iflytek 4096 5月 28 17:18 software
```

#### 6) 卸载虚拟机自带的 JDK

#### 注意: 如果你的虚拟机是最小化安装不需要执行这一步。

[root@hadoop100 ~]# rpm -qa | grep -i java | xargs -n1 rpm -e -nodeps

- ▶ rpm -qa: 查询所安装的所有 rpm 软件包
- ▶ grep -i: 忽略大小写
- > xargs -n1:表示每次只传递一个参数
- ➤ rpm -e -nodeps: 强制卸载软件

#### 7) 重启虚拟机

[root@hadoop100 ~]# reboot

## 1.2 克隆虚拟机

1) 利用模板机 hadoop100, 克隆三台虚拟机: hadoop102、hadoop103、hadoop104

### 注意:克隆时,要先关闭 hadoop100。

#### 2) 修改克隆机 IP, 以下以 hadoop102 举例说明

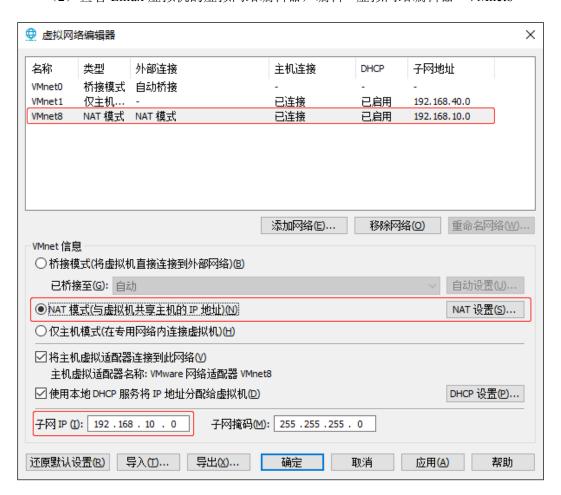
(1) 修改克隆虚拟机的静态 IP

[iflytek@hadoop100 ~]# sudo vim /etc/sysconfig/networkscripts/ifcfg-ens33

改成

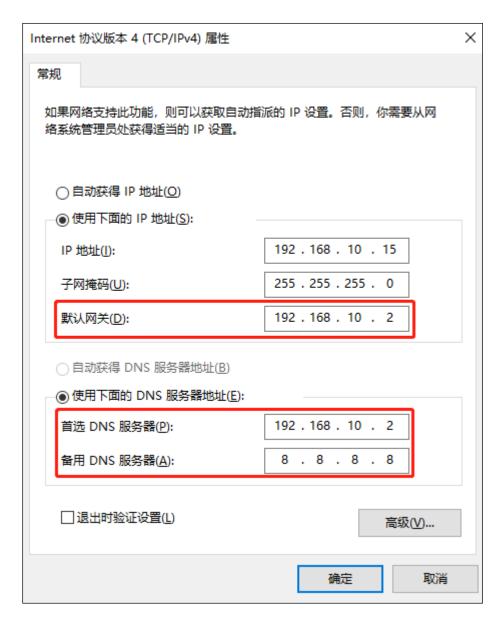
DEVICE=ens33
TYPE=Ethernet
ONBOOT=yes
BOOTPROTO=static
NAME="ens33"
IPADDR=192.168.10.102
PREFIX=24
GATEWAY=192.168.10.2
DNS1=192.168.10.2

(2) 查看 Linux 虚拟机的虚拟网络编辑器,编辑->虚拟网络编辑器->VMnet8





(3) 查看 Windows 系统适配器 VMware Network Adapter VMnet8 的 IP 地址



(4) 保证 Linux 系统 ifcfg-ens33 文件中 IP 地址、虚拟网络编辑器地址和 Windows 系统 VM8 网络 IP 地址相同。

#### 3) 修改克隆机主机名,以下以 hadoop102 举例说明

(1) 修改主机名称

[iflytek@hadoop100 ~]# sudo vim /etc/hostname
hadoop102

(2) 配置 Linux 克隆机主机名称映射 hosts 文件, 打开/etc/hosts

[iflytek@hadoop100 ~]# sudo vim /etc/hosts

添加如下内容

```
192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
```

```
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

#### 4) 重启克隆机 hadoop102

[iflytek@hadoop100 ~] # sudo reboot

- 5) 修改 windows 的主机映射文件(hosts 文件)
  - (1) 如果操作系统是 window7, 可以直接修改
  - ①进入 C:\Windows\System32\drivers\etc 路径
  - ②打开 hosts 文件并添加如下内容, 然后保存

```
192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

- (2) 如果操作系统是 window10, 先拷贝出来, 修改保存以后, 再覆盖即可
- ①进入 C:\Windows\System32\drivers\etc 路径
- ②拷贝 hosts 文件到桌面
- ③打开桌面 hosts 文件并添加如下内容

```
192.168.10.100 hadoop100
192.168.10.101 hadoop101
192.168.10.102 hadoop102
192.168.10.103 hadoop103
192.168.10.104 hadoop104
192.168.10.105 hadoop105
192.168.10.106 hadoop106
192.168.10.107 hadoop107
192.168.10.108 hadoop108
```

④将桌面 hosts 文件覆盖 C:\Windows\System32\drivers\etc 路径 hosts 文件

## 1.3 编写集群分发脚本 xsync

- 1) xsync 集群分发脚本
  - (1) 脚本实现
  - ①在用的家目录/home/iflytek 下创建 bin 文件夹

```
[iflytek@hadoop102 ~]$ cd /home/iflytek
[iflytek@hadoop102 ~]$ mkdir bin
```

②在/home/iflytek/bin 目录下创建 xsync 文件,以便全局调用

```
[iflytek@hadoop102 ~]$ cd /home/iflytek/bin
[iflytek@hadoop102 ~]$ vim xsync
```

```
#!/bin/bash
#1. 判断参数个数
if [ $# -lt 1 ]
then
 echo Not Enough Arguement!
 exit;
fi
#2. 遍历集群所有机器
for host in hadoop102 hadoop103 hadoop104
 #3. 遍历所有目录, 挨个发送
 for file in $@
 do
  #4 判断文件是否存在
  if [ -e $file ]
  then
    #5. 获取父目录
    pdir=$(cd -P $(dirname $file); pwd)
    #6. 获取当前文件的名称
    fname=$(basename $file)
   ssh $host "mkdir -p $pdir"
   rsync -av $pdir/$fname $host:$pdir
  else
    echo $file does not exists!
 done
done
```

③修改脚本 xsync 具有执行权限

[iflytek@hadoop102 bin]\$ chmod 777 xsync

④测试脚本

[iflytek@hadoop102 bin]\$ xsync xsync

### 1.4 SSH 无密登录配置

说明: 这里面只配置了 hadoop102、hadoop103 到其他主机的无密登录; 因为 hadoop102 配置的是 NameNode, hadoop103 配置的是 ResourceManager, 都要求对其他节点无密访问。

(1) hadoop102 上生成公钥和私钥:

```
[iflytek@hadoop102 .ssh]$ ssh-keygen -t rsa
然后敲(三个回车),就会生成两个文件 id_rsa(私钥)、id_rsa.pub(公钥)。
```

(2) 将 hadoop102 公钥拷贝到要免密登录的目标机器上

```
[iflytek@hadoop102 .ssh]$ ssh-copy-id hadoop102
[iflytek@hadoop102 .ssh]$ ssh-copy-id hadoop103
[iflytek@hadoop102 .ssh]$ ssh-copy-id hadoop104
```

(3) hadoop103 上生成公钥和私钥:

```
[iflytek@hadoop103 .ssh]$ ssh-keygen -t rsa
```

然后敲(三个回车),就会生成两个文件 id rsa(私钥)、id rsa.pub(公钥)。

(4) 将 hadoop103 公钥拷贝到要免密登录的目标机器上

```
[iflytek@hadoop103 .ssh]$ ssh-copy-id hadoop102
[iflytek@hadoop103 .ssh]$ ssh-copy-id hadoop103
[iflytek@hadoop103 .ssh]$ ssh-copy-id hadoop104
```

### 1.5 JDK 准备

#### 1) 卸载现有 JDK (3 台节点)

```
[iflytek@hadoop102 opt]# sudo rpm -qa | grep -i java | xargs -n1
sudo rpm -e --nodeps

[iflytek@hadoop103 opt]# sudo rpm -qa | grep -i java | xargs -n1
sudo rpm -e --nodeps

[iflytek@hadoop104 opt]# sudo rpm -qa | grep -i java | xargs -n1
sudo rpm -e --nodeps
```

- (1) rpm -qa: 表示查询所有已经安装的软件包
- (2) grep -i: 表示过滤时不区分大小写
- (3) xargs -n1:表示一次获取上次执行结果的一个值
- (4) rpm -e --nodeps: 表示卸载软件
- 2) 用 XShell 工具将 JDK 导入到 hadoop102 的/opt/software 文件夹下面
- 3) 在 Linux 系统下的 opt 目录中查看软件包是否导入成功

[iflytek@hadoop102 software]# ls /opt/software/ 看到如下结果:

jdk-8u212-linux-x64.tar.gz

#### 4) 解压 JDK 到/opt/module 目录下

```
[iflytek@hadoop102 software]# tar -zxvf jdk-8u212-linux-
x64.tar.gz -C /opt/module/
[iflytek@hadoop102 module]$ mv jdk1.8.0 212/ jdk-1.8.0
```

#### 5) 配置 JDK 环境变量

(1) 新建/etc/profile.d/my env.sh 文件

[iflytek@hadoop102 module]# sudo vim /etc/profile.d/my\_env.sh

添加如下内容,然后保存(:wq)退出。

```
#JAVA_HOME
export JAVA_HOME=/opt/module/jdk-1.8.0
export PATH=$PATH:$JAVA_HOME/bin
```

(2) 让环境变量生效

[iflytek@hadoop102 software]\$ source /etc/profile.d/my env.sh

#### 6) 测试 JDK 是否安装成功

[iflytek@hadoop102 module]# java -version

如果能看到以下结果、则 Java 正常安装。

java version "1.8.0 212"

#### 7) 分发 JDK

[iflytek@hadoop102 module]\$ xsync /opt/module/jdk-1.8.0

#### 8) 分发环境变量配置文件

[iflytek@hadoop102 module]\$ sudo /home/iflytek/bin/xsync /etc/profile.d/my env.sh

#### 9) 分别在 hadoop103、hadoop104 上执行 source

```
[iflytek@hadoop103 module]$ source /etc/profile.d/my_env.sh
[iflytek@hadoop104 module]$ source /etc/profile.d/my env.sh
```

## 第2章 Hadoop 完全分布式集群搭建

分析:

- 1)准备3台客户机(关闭防火墙、静态IP、主机名称)
- 2) 安装 JDK
- 3) 配置环境变量
- 4) 安装 Hadoop
- 5) 配置环境变量
- 6) 配置集群
- 7) 单点启动
- 8) 配置 ssh
- 9) 群起并测试集群

## 1.1 Hadoop 部署

#### 1) 集群部署规划

注意: NameNode 和 SecondaryNameNode 不要安装在同一台服务器

注意: ResourceManager 也很消耗内存,不要和 NameNode、SecondaryNameNode 配置在同一台机器上。

	hadoop102	hadoop103	hadoop104
HDFS	NameNode		SecondaryNameNode
	DataNode	DataNode	DataNode
YARN		ResourceManager	
	NodeManager	NodeManager	NodeManager

- 2) 将 hadoop3.3.4.tar.gz 导入到 opt 目录下面的 software 文件夹下面
- 3) 进入到 Hadoop 安装包路径下

[iflytek@hadoop102 ~]\$ cd /opt/software/

#### 4) 解压安装文件到/opt/module 下面

[iflytek@hadoop102 software]\$ tar -zxvf hadoop-3.3.4.tar.gz -C
/opt/module/

#### 5) 查看是否解压成功

[iflytek@hadoop102 software] \$ ls /opt/module/hadoop-3.3.4

#### 6) 重命名

```
[iflytek@hadoop102 software]$ mv /opt/module/hadoop-3.3.4
/opt/module/hadoop
```

#### 7) 将 Hadoop 添加到环境变量

(1) 获取 Hadoop 安装路径

```
[iflytek@hadoop102 hadoop]$ pwd
/opt/module/hadoop
```

(2) 打开/etc/profile.d/my env.sh 文件

[iflytek@hadoop102 hadoop]\$ sudo vim /etc/profile.d/my\_env.sh

在 profile 文件末尾添加 JDK 路径: (shitf+g)

```
#HADOOP_HOME
export HADOOP_HOME=/opt/module/hadoop
export PATH=$PATH:$HADOOP_HOME/bin
export PATH=$PATH:$HADOOP_HOME/sbin
```

(3) 保存后退出

:wq

(4) 分发环境变量文件

```
[iflytek@hadoop102 hadoop]$ sudo /home/iflytek/bin/xsync
/etc/profile.d/my env.sh
```

(5) source 是之生效 (3 台节点)

```
[iflytek@hadoop102 module]$ source /etc/profile.d/my_env.sh
[iflytek@hadoop103 module]$ source /etc/profile.d/my_env.sh
[iflytek@hadoop104 module]$ source /etc/profile.d/my env.sh
```

## 1.2 配置集群

1)核心配置文件

配置 core-site.xml

```
[iflytek@hadoop102 ~]$ cd $HADOOP_HOME/etc/hadoop
[iflytek@hadoop102 hadoop]$ vim core-site.xml
```

文件内容如下:

```
<value>hdfs://hadoop102:8020</value>
   </property>
   <!-- 指定 hadoop 数据的存储目录 -->
   cproperty>
      <name>hadoop.tmp.dir</name>
      <value>/opt/module/hadoop/data</value>
   </property>
   <!-- 配置 HDFS 网页登录使用的静态用户为 iflytek -->
   property>
      <name>hadoop.http.staticuser.user</name>
      <value>iflytek</value>
   </property>
   <!-- 配置该 iflytek (superUser) 允许通过代理访问的主机节点 -->
   cproperty>
      <name>hadoop.proxyuser.iflytek.hosts
      <value>*</value>
   </property>
   <!-- 配置该 iflytek (superUser) 允许通过代理用户所属组 -->
      <name>hadoop.proxyuser.iflytek.groups</name>
      <value>*</value>
   </property>
   <!-- 配置该 iflytek (superUser) 允许通过代理的用户-->
      <name>hadoop.proxyuser.iflytek.users
      <value>*</value>
   </property>
</configuration>
```

#### 2) HDFS 配置文件

配置 hdfs-site.xml

[iflytek@hadoop102 hadoop]\$ vim hdfs-site.xml

文件内容如下:

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
   <!-- nn web 端访问地址-->
   cproperty>
      <name>dfs.namenode.http-address
      <value>hadoop102:9870</value>
   </property>
   <!-- 2nn web 端访问地址-->
   cproperty>
      <name>dfs.namenode.secondary.http-address
      <value>hadoop104:9868</value>
   </property>
   <!-- 测试环境指定 HDFS 副本的数量 1 -->
   cproperty>
      <name>dfs.replication</name>
      <value>1</value>
```

```
</property>
</configuration>
```

#### 3) YARN 配置文件

配置 yarn-site.xml

[iflytek@hadoop102 hadoop]\$ vim yarn-site.xml

文件内容如下:

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
<configuration>
   <!-- 指定 MR 走 shuffle -->
   cproperty>
      <name>yarn.nodemanager.aux-services
      <value>mapreduce shuffle</value>
   </property>
   <!-- 指定 ResourceManager 的地址-->
   cproperty>
      <name>yarn.resourcemanager.hostname</name>
      <value>hadoop103</value>
   </property>
   <!-- 环境变量的继承 -->
   cproperty>
      <name>yarn.nodemanager.env-whitelist</name>
<value>JAVA HOME, HADOOP COMMON HOME, HADOOP HDFS HOME, HADOOP CONF
DIR, CLASSPATH PREPEND DISTCACHE, HADOOP YARN HOME, HADOOP MAPRED HO
ME</value>
   </property>
   <!--yarn 单个容器允许分配的最大最小内存 -->
   cproperty>
      <name>yarn.scheduler.minimum-allocation-mb</name>
      <value>512</value>
   </property>
   cproperty>
      <name>yarn.scheduler.maximum-allocation-mb</name>
      <value>4096</value>
   </property>
   <!-- yarn 容器允许管理的物理内存大小 -->
   cproperty>
      <name>yarn.nodemanager.resource.memory-mb</name>
      <value>4096</value>
   </property>
   <!-- 关闭 yarn 对物理内存和虚拟内存的限制检查 -->
      <name>yarn.nodemanager.pmem-check-enabled</name>
      <value>false</value>
   </property>
   property>
      <name>yarn.nodemanager.vmem-check-enabled
      <value>false</value>
```

```
</property>
</configuration>
```

4) MapReduce 配置文件

配置 mapred-site.xml

[iflytek@hadoop102 hadoop] vim mapred-site.xml

文件内容如下:

5) 配置 workers

[iflytek@hadoop102 hadoop]\$ vim
/opt/module/hadoop/etc/hadoop/workers

在该文件中增加如下内容:

```
hadoop102
hadoop103
hadoop104
```

注意:该文件中添加的内容结尾不允许有空格,文件中不允许有空行。

## 1.3 配置历史服务器

为了查看程序的历史运行情况,需要配置一下历史服务器。具体配置步骤如下:

#### 1) 配置 mapred-site.xml

[iflytek@hadoop102 hadoop]\$ vim mapred-site.xml

在该文件里面增加如下配置。

### 1.4 配置日志的聚集

日志聚集概念:应用运行完成以后,将程序运行日志信息上传到 HDFS 系统上。

日志聚集功能好处:可以方便的查看到程序运行详情,方便开发调试。

注意: 开启日志聚集功能,需要重新启动 NodeManager 、ResourceManager 和

#### HistoryManager.

开启日志聚集功能具体步骤如下:

#### 1) 配置 yarn-site.xml

[iflytek@hadoop102 hadoop]\$ vim yarn-site.xml

在该文件里面增加如下配置。

## 1.5 分发 Hadoop

[iflytek@hadoop102 hadoop]\$ xsync /opt/module/hadoop/

## 1.6 群起集群

#### 1) 启动集群

(1) 如果集群是第一次启动,需要在 hadoop102 节点格式化 NameNode (注意格式化

之前,一定要先停止上次启动的所有 namenode 和 datanode 进程,然后再删除 data 和 log 数据)

```
[iflytek@hadoop102 bin]$ cd /opt/module/hadoop/
[iflytek@hadoop102 hadoop]$ bin/hdfs namenode -format
```

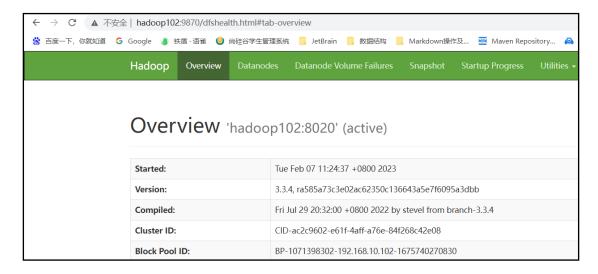
(2) 启动 HDFS

[iflytek@hadoop102 hadoop]\$ sbin/start-dfs.sh

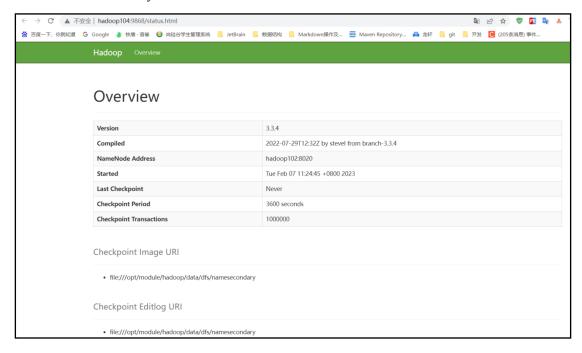
(3) 在配置了 ResourceManager 的节点(hadoop103) 启动 YARN

[iflytek@hadoop103 hadoop]\$ sbin/start-yarn.sh

(4) Web 端查看 HDFS 的 Web 页面: http://hadoop102:9870/



- (5) Web 端查看 SecondaryNameNode
- ① 浏览器中输入: http://hadoop104:9868/status.html
- ② 查看 SecondaryNameNode 信息



## 1.7 Hadoop 群起脚本

(1) 在/home/iflytek/bin 目录下创建 hdp.sh

```
[iflytek@hadoop102 bin]$ cd /home/iflytek/bin
[iflytek@hadoop102 bin]$ vim hdp.sh
```

(2) 写入以下内容:

```
#!/bin/bash
if [ $# -lt 1 ]
then
    echo "No Args Input..."
    exit;
fi
```

```
case $1 in
"start")
    echo " ========= 启 动
                                     hadoop 集
                                              群
----"
     echo " ------- 启动 hdfs -----"
     ssh hadoop102 "/opt/module/hadoop/sbin/start-dfs.sh"
     echo " ------- 启动 yarn -----"
     ssh hadoop103 "/opt/module/hadoop/sbin/start-yarn.sh"
     echo " ------ 启动 historyserver -----"
     ssh hadoop102 "/opt/module/hadoop/bin/mapred --daemon start
;;
"stop")
                                     hadoop 集 群
            echo
==================
     ssh hadoop102 "/opt/module/hadoop/bin/mapred --daemon stop
historyserver"
    ssh hadoop103 "/opt/module/hadoop/sbin/stop-yarn.sh"
     ssh hadoop102 "/opt/module/hadoop/sbin/stop-dfs.sh"
;;
*)
  echo "Input Args Error..."
;;
esac
   (3) 增加权限
[iflytek@hadoop102 bin]$ chmod 777 hdp.sh
   (4) 启动集群
[iflytek@hadoop102 bin]$ hdp.sh start
  日志如下。
----- 启动 hdfs -----
Starting namenodes on [hadoop102]
Starting datanodes
Starting secondary namenodes [hadoop104]
----- 启动 yarn ------
Starting resourcemanager
Starting nodemanagers
----- 启动 historyserver ------
  查看进程。
[iflytek@hadoop102 bin]$ xcall jps
  结果如下。
----- hadoop102 -----
3074 Jps
2116 NameNode
2245 DataNode
2761 JobHistoryServer
2590 NodeManager
```

```
----- hadoop103 -----
3270 NodeManager
2952 DataNode
3148 ResourceManager
3854 Jps
----- hadoop104 -----
1889 DataNode
2100 NodeManager
2446 Jps
1967 SecondaryNameNode
   (5) 停止集群
[iflytek@hadoop102 bin]$ hdp.sh stop
----- 关闭 historyserver ------
----- 关闭 yarn ------
Stopping nodemanagers
Stopping resourcemanager
----- 关闭 hdfs ------
Stopping namenodes on [hadoop102]
Stopping datanodes
Stopping secondary namenodes [hadoop104]
  查看进程。
[iflytek@hadoop102 bin]$ xcall jps
  结果如下。
----- hadoop102 -----
3691 Jps
----- hadoop103 -----
4221 Jps
----- hadoop104 -----
```

2647 Jps